Universidade Federal de Santa Maria

Disciplina de Inteligência Artificial

Trabalho de Aprendizado Supervisionado

Objetivo: Desenvolver um pipeline completo de Machine Learning/Redes Neurais, utilizando um problema real, contemplando análise exploratória dos dados, pré-processamento, engenharia de atributos, classificação, regressão, Redes Neurais Multicamadas (MLP), comparação com métodos tradicionais de Machine Learning, otimização de hiperparâmetros e análise de generalização.

Problema: Predição de atropelamentos e identificação de hotspots de fauna silvestre.

Fonte dos dados: O Projeto RodoFauna é uma iniciativa do Instituto Brasília Ambiental (IBRAM/DF) criada para estudar o impacto das rodovias sobre a fauna silvestre do Distrito Federal.

O projeto realizou percursos sistemáticos em trechos rodoviários, registrando animais encontrados atropelados, identificando-os taxonomicamente e georreferenciando os locais das ocorrências. Entre abril de 2010 e março de 2015, foram realizados 484 percursos, cobrindo aproximadamente 55.176 km de rodovias. Foram registrados milhares de animais atropelados, grande parte deles silvestres, pertencentes a diferentes espécies de aves, répteis, mamíferos e anfíbios.

Atualmente, os dados estão disponíveis por meio do serviço GIS do IBRAM denominado Programa Rodofauna Atropelada, cuja camada contém pontos geográficos correspondentes às ocorrências registradas.

Fonte:

https://www.arcgis.com/apps/mapviewer/index.html?url=https://onda.ibram.df.gov.br/server/rest/services/Monitoramento_Ambiental/Programa_Rodofauna_Atropelada/FeatureServer/2&source=sd

Neste contexto, a base do RodoFauna permite desenvolver modelos de Machine Learning espacial para investigar a ocorrência, o tipo e a intensidade dos atropelamentos de fauna.

Atributos disponíveis: A base contém, entre outros, os seguintes campos:

Atributo/ variável	Exemplo
id	1
campanha	1
ano	2010
periodo	1
mes	abril
data_dt	05/04/10
dia_da_sem	seg
silvestre_	silvestre
classe	birds
ordem	apodiformes
familia	apodidae
especie_nm	streptoprocne_zonaris
nome_popul	andorinhao_de_coleira
uc	esecae
x	219467
y	8273815
posicao	nao_identificado
hora	nao_identificado

sexo	nao_identificado

Para este trabalho, devem ser utilizados **apenas registros referentes à fauna silvestre**.

Os seguintes campos não devem ser utilizados diretamente como atributos preditores: id; silvestre_, após a filtragem dos registros silvestres; hora; sexo; posição; ordem; família; nome_popul; campanha; periodo. O campo mes não precisa ser utilizado diretamente, pois essa informação pode ser obtida a partir de data_dt.

Campos como classe e especie_nm podem ser utilizados como variáveis alvo, dependendo do problema investigado, mas não devem ser empregados como atributos de entrada quando representarem uma informação que somente seria conhecida após a ocorrência do atropelamento.

Entre os atributos potencialmente úteis encontram-se: uc: contexto ecológico e espacial; x e y: coordenadas planas UTM; data_dt: permite derivar atributos temporais; ano; dia_da_sem; classe: possível variável alvo para classificação multiclasse; especie_nm: possível variável alvo para problemas específicos envolvendo espécies.

Engenharia de atributos

A partir dos atributos originais, o grupo poderá criar novas variáveis, como:

- mês;

- estação do ano;

- período seco/chuvoso;

- dia do ano;

- final de semana/dia útil;

- localização ou segmento rodoviário;

- distância entre ocorrências;

- número de ocorrências em determinada região;

- densidade espacial de atropelamentos.

Também poderão ser incorporados dados externos, desde que sua origem seja documentada, como:

- precipitação;

- temperatura;

- uso e cobertura do solo;

- distância a corpos d'água;

- distância a áreas de vegetação;

- distância a Unidades de Conservação;

- características da rodovia;

- volume de tráfego;

- velocidade máxima permitida;

- relevo ou elevação.

Problemas de Machine Learning: O trabalho deverá contemplar classificação e regressão.

1. Classificação binária

Desenvolver um modelo para distinguir duas classes relacionadas ao risco ou à ocorrência de atropelamentos.

Uma possibilidade é dividir a área ou a malha rodoviária em segmentos espaciais e definir:

- 1 — segmento com ocorrência ou alto risco de atropelamento;

- 0 — segmento sem ocorrência ou baixo risco de atropelamento.

A definição de alto e baixo risco deverá ser explicitamente justificada pelo grupo.

Por exemplo, os segmentos podem ser classificados a partir:

- da existência ou ausência de atropelamentos;

- de um limiar sobre o número de atropelamentos;

- da taxa de atropelamentos observada;

- de critérios baseados na distribuição estatística dos registros.

Atenção: a base é constituída por registros de ocorrências. Portanto, caso sejam necessárias amostras da classe "sem atropelamento", o grupo deverá explicar claramente como essas amostras foram obtidas. Não é adequado considerar simplesmente a ausência de um ponto na base como evidência automática de ausência de risco.

2. Classificação multiclasse

Desenvolver um problema envolvendo três ou mais classes. Possibilidades incluem:

Classificação por grupo taxonômico. Por exemplo:

- aves;

- mamíferos;

- répteis;

- anfíbios.

Neste caso, classe pode ser utilizada como variável alvo.

Classificação por níveis de risco. Por exemplo:

- baixo risco;

- médio risco;

- alto risco.

Os limiares utilizados para construir as classes deverão ser definidos e justificados estatisticamente.

Classificação por espécie. Também é possível prever espécies ou grupos de espécies, desde que haja quantidade suficiente de exemplos em cada classe.

Evite problemas com classes extremamente raras. Caso a distribuição por espécie seja muito desbalanceada, recomenda-se agrupar os registros em classes taxonômicas ou selecionar apenas espécies com número mínimo de ocorrências.

3. Regressão

Desenvolver um modelo capaz de prever uma variável quantitativa relacionada aos atropelamentos. Exemplos:

- número de atropelamentos por segmento rodoviário;

- número de atropelamentos por região;

- número de atropelamentos por espécie;

- número de atropelamentos por segmento e período;

- taxa de atropelamentos.

Para regressão, os registros individuais deverão ser agregados em unidades espaciais e/ou temporais.

Por exemplo: número de atropelamentos por segmento rodoviário por mês.

A escolha da unidade espacial e temporal deverá ser justificada.

Etapa 1 – Análise Exploratória do Dataset

Realizar uma análise inicial dos dados e apresentar:

- descrição do problema;

- quantidade de registros;

- quantidade de atributos;

- tipos dos atributos;

- quantidade de valores ausentes;

- variável alvo de cada experimento;

- distribuição das classes, quando aplicável;

- estatísticas descritivas das variáveis numéricas;

- distribuição espacial dos atropelamentos;

- distribuição temporal dos atropelamentos.

Investigar possíveis problemas, incluindo:

- classes desbalanceadas;

- valores ausentes;

- atributos com grande quantidade de valores não_identificado;

- outliers;

- atributos redundantes;

- correlação elevada entre atributos;

- classes com quantidade insuficiente de exemplos.

Sempre que possível, apresentar visualizações gráficas.

Etapa 2 – Pré-processamento

Realizar o tratamento necessário para a construção dos modelos.

Codificação de variáveis categóricas

Exemplos:

- One-Hot Encoding;

- Ordinal Encoding;

- outras estratégias devidamente justificadas.

Evite utilizar Label Encoding em variáveis nominais de entrada quando os valores numéricos produzidos criarem uma ordem artificial entre as categorias.

Normalização ou padronização

Exemplos:

- StandardScaler;

- MinMaxScaler;

- RobustScaler.

A normalização/padronização é particularmente importante para o treinamento da MLP.

O grupo deverá justificar todas as escolhas realizadas.

Divisão dos dados

Separar adequadamente os dados em:

- treinamento;

- validação;

- teste.

O conjunto de teste deverá permanecer separado durante a escolha dos hiperparâmetros.

Devido à natureza espacial dos dados, o grupo deverá discutir se uma divisão completamente aleatória pode produzir resultados excessivamente otimistas quando registros geograficamente muito próximos aparecem simultaneamente nos conjuntos de treinamento e teste.

Sempre que possível, realizar também um experimento utilizando divisão espacial ou temporal, por exemplo:

- treinamento em determinadas regiões e teste em outras;

- treinamento em determinados anos/períodos e teste em períodos posteriores.

Etapa 3 – Classificação com MLP

Desenvolver uma Rede Neural Multicamadas (MLP) para resolver pelo menos um dos problemas de classificação propostos.

A implementação poderá ser realizada utilizando:

- Scikit-Learn (MLPClassifier);

- TensorFlow/Keras;

- PyTorch.

O grupo deverá definir e justificar:

- número de camadas ocultas;

- número de neurônios por camada;

- funções de ativação;

- otimizador;

- taxa de aprendizado;

- número de épocas;

- tamanho do batch.

Avaliação

Para classificação binária, apresentar:

- Accuracy;

- Precision;

- Recall;

- F1-Score;

- ROC-AUC;

- matriz de confusão.

Em caso de classes desbalanceadas, discutir por que Accuracy isoladamente pode ser inadequada.

Para classificação multiclasse, apresentar:

- Accuracy;

- Precision Macro;

- Recall Macro;

- F1 Macro;

- matriz de confusão.

Quando aplicável, apresentar também métricas por classe.

Curvas de treinamento, apresentar:

- loss de treinamento e validação por época;

- evolução da principal métrica de classificação durante o treinamento.

Comparação com modelo tradicional

Comparar a MLP com pelo menos um método clássico de Machine Learning, por exemplo:

- Random Forest;

- Logistic Regression;

- Gradient Boosting.

A comparação deverá utilizar exatamente as mesmas divisões de treinamento e teste.

Discutir:

- desempenho;

- capacidade de generalização;

- sensibilidade ao pré-processamento;

- custo computacional;

- facilidade de interpretação.

Etapa 4 – Regressão com MLP

Desenvolver uma Rede Neural Multicamadas para o problema de regressão definido anteriormente.

A implementação poderá ser realizada utilizando:

- Scikit-Learn (MLPRegressor);

- TensorFlow/Keras;

- PyTorch.

O grupo deverá definir e justificar:

- número de camadas ocultas;

- número de neurônios;

- funções de ativação;

- otimizador;

- taxa de aprendizado;

- número de épocas;

- batch size.

Avaliação, apresentar:

- MAE;

- MSE;

- RMSE;

- R^2.

Apresentar também:

- gráfico de valores reais × valores preditos;

- gráfico de resíduos;

- curva de loss de treinamento e validação.

Comparar a MLP com pelo menos um método tradicional de regressão, por exemplo:

- Regressão Linear;

- Random Forest Regressor;

- Gradient Boosting Regressor.

Discutir vantagens e desvantagens das abordagens.

Etapa 5 – Otimização de Hiperparâmetros com Optuna

Utilizar o Optuna para otimizar os hiperparâmetros de pelo menos uma das Redes Neurais Multicamadas desenvolvidas anteriormente.

O grupo deverá definir um espaço de busca e justificar seus limites.

Exemplos de hiperparâmetros

Arquitetura

- número de camadas ocultas;

- número de neurônios por camada;

- funções de ativação.

Treinamento

- Learning Rate;

- Batch Size;

- número máximo de épocas.

Otimizador

- Adam;

- SGD;

- RMSprop;

- outros;

- Momentum, quando aplicável.

Regularização

- Dropout;

- Weight Decay/L2.

Função objetivo: A função objetivo deverá ser escolhida de acordo com o problema.

Exemplos:

Classificação:

- maximizar F1 Macro;

- maximizar F1;

- maximizar ROC-AUC.

Regressão:

- minimizar RMSE;

- minimizar MAE.

O conjunto de teste não deverá ser utilizado pelo Optuna para selecionar hiperparâmetros. A otimização deverá ocorrer exclusivamente sobre treinamento/validação.

Resultados, apresentar:

- espaço de busca;

- quantidade de trials;

- melhor conjunto de hiperparâmetros;

- valor da função objetivo;

- histórico da otimização;

- importância dos hiperparâmetros, quando disponível.

Comparar:

- modelo original;

- modelo otimizado.

Discutir:

- ganhos de desempenho;

- impacto sobre o tempo de treinamento;

- hiperparâmetros mais relevantes encontrados pelo Optuna.

Etapa 6 – Regularização e Análise de Overfitting

Investigar o comportamento da MLP em relação a overfitting e underfitting.

Aplicar pelo menos uma técnica de regularização.

Técnicas possíveis

Dropout

Inserção de camadas de Dropout para reduzir dependências excessivas entre unidades da rede.

Weight Decay / Regularização L2

Penalização de pesos elevados durante o treinamento.

Early Stopping

Interrupção do treinamento quando não houver melhora no conjunto de validação durante determinado número de épocas.

Redução da complexidade

- redução do número de camadas;

- redução do número de neurônios.

Avaliação, apresentar curvas de:

- treinamento;

- validação.

Comparar: MLP sem regularização × MLP com regularização

Analisar:

- existência de overfitting;

- existência de underfitting;

- diferença entre treinamento e validação;

- impacto da regularização nas métricas finais;

- impacto sobre a capacidade de generalização.

Responder:

1. A rede apresentou sinais de overfitting?

2. Qual técnica de regularização foi utilizada?

3. Houve melhoria de desempenho em dados não vistos?

4. Qual configuração apresentou melhor equilíbrio entre desempenho e generalização?

Etapa 7 – Discussão Final

Além das análises anteriores, discutir criticamente:

1. Quais atributos parecem ter maior relação com a ocorrência de atropelamentos?

2. A MLP apresentou desempenho superior aos métodos tradicionais?

3. O aumento da complexidade da rede resultou em melhor desempenho?

4. Qual foi o impacto do desbalanceamento das classes?

5. Os resultados mudaram após a otimização dos hiperparâmetros?

6. Os modelos parecem capazes de generalizar para regiões ou períodos não utilizados no treinamento?

7. Quais são as principais limitações do conjunto de dados?

8. Quais atributos adicionais poderiam melhorar a predição?

9. Como o modelo poderia ser utilizado para identificar potenciais hotspots de atropelamento?

Possíveis mudanças que podem ser consideradas no trabalho:

1. Multiclasse: usar como exemplo principal aves × mamíferos × répteis × anfíbios, e não espécies. Por espécie, pode haver muitas classes com poucas amostras.

2. Hotspot binário: construir a unidade de análise — por exemplo, segmento de 500 m — e definir o que é alto/baixo risco. Os pontos do RodoFauna isoladamente não fornecem a classe negativa.

3. Generalização espacial: discutir — e testar — split espacial ou temporal. Com coordenadas X/Y e random split, dois atropelamentos praticamente vizinhos podem cair em treino e teste e produzir uma estimativa exageradamente otimista do desempenho.

Entregas

Trabalho em grupo de no máximo 3 alunos.

O trabalho deverá ser entregue por e-mail para:

racosta@inf.ufsm.br

luisalvaro@inf.ufsm.br

Enviar um único arquivo .zip, identificado com o nome dos integrantes do grupo, contendo:

- relatório técnico do trabalho;

- código-fonte;

- dados utilizados;

- arquivos necessários para reprodução dos experimentos;

- outros materiais utilizados durante o desenvolvimento;

- vídeo de no máximo 10 minutos, apresentando o problema, metodologia, principais experimentos e resultados.